

用于超分辨率 3D 激光雷达成像的基于多尺度直方图的概率深度神经网络

孙森, 卓圣龙*, 蒋寅

复旦大学专用集成电路与系统国家重点实验室, 上海张衡路 825 号, 邮编 201203, 中国 * 通信作者: shenglongzhuo198881@gmail.com

摘要: 基于单光子雪崩二极管 (SPAD) 技术的激光雷达 (LiDAR) 成像, 因高精度测量深度值所需的大型片上直方图峰值检测电路而遭受严重的面积惩罚。在这项工作中, 提出了一种基于概率估计的 SPAD 成像超分辨率神经网络, 该网络首先使用时间多尺度直方图作为输入。为了减少片上直方图计算的面积和成本, 芯片上仅实现了用于计算反射光子的部分直方图硬件。基于返回光子的分布规律, 首次提出了一种概率编码器作为网络的一部分来解决 SPAD 的深度估计问题。通过将该神经网络与超分辨率网络联合使用, 利用 $16\times$ 多尺度直方图输出实现了 32×32 上采样深度估计。最后, 在实验室中使用 32×32 SPAD 传感器系统验证了该神经网络的有效性。

关键词: SPAD 传感器; 激光雷达成像; 神经网络; 超分辨率

1. 引言

激光雷达在自动驾驶车辆的感知和定位中起着至关重要的作用, 但在实际场景中, 原始传感器的深度信息存在空间和时间噪声以及分辨率问题。最近, 基于直接飞行时间 (dToF) 的深度传感技术出现了, 但其像素分辨率和功耗对于传感器设计者来说难以平衡。随着超分辨率神经网络的更广泛应用, 可以在 RGB 图像的引导下将深度图从低分辨率上采样到高分辨率。这使得 dToF 传感器能够在有限的像素数量和功耗内输出高质量的深度图。下面将分别介绍一些在深度图上进行上采样的硬件和算法工作。

在传感器设计领域, 关于提高 SPAD 传感器像素密度的研究已经进行了几十年, 从 128×128 传感器 [1] 到基于 3D 堆叠工艺的百万像素阵列 [2]。由于 SPAD 器件技术的成熟, 已经实现了更少的像素数量、更高的填充因子和更低的暗计数率 (DCR) [3]。除了器件改进, 许多研究都集中在数字信号处理上。在 [4 - 6] 中, 芯片面积主要由直方图数据存储的内存资源、时间数字转换器 (TDC) 和深度计算单元占据。此外, 由于大量原始直方图数据输出, 硬件速度受到高带宽 IO 要求的限制。在 [7] 中, Zhang 等人开发了一种部分直方图方法, 以 14.9 比 1 的比例节省数字逻辑和片上 SRAM 面积。然而, 这些数字信号处理器只专注于硬件优化。由于灵活性有限, 难以实现传感器性能与片上资源之间的权衡。

最近, 神经网络被引入以提高 3D 成像的质量。在 [8 - 12] 中, 神经网络能够从大量具有显著空间和时间噪声的反射光子中恢复深度信息, 如多路径反射和环境光。此外, 由于神经网络内部的空间和时间相关性, RGB 和强度信息可以作为先验知识被充分利用, 以进一步改善 3D 图像。在 [8] 中, 通过将稀疏点云和灰度数据作为 3D 卷积神经网络的输入, 滤除了时间噪声并提高了空间密度。为了实现更好的端到端超分辨率成像质量, [9] 的作者将光学相板图案及其空间图案分布函数作为神经网络的先验知识, 将光学设计与重建神经网络相结合。[10] 的作者提出了一种用于高速 3D 传感的两步插值方案, 并展示了一个帧率超过 1k - fps 的高质量成像系统。在 [11] 中设计了一种使用第一深度图和第二深度图的多特征神经网络来获得上采样深度, 并在 [12] 中证明了小批量目标分割的可行性。

引用:Sun, M.; Zhuo, S.; Chiang, P.Y. 用于超分辨率 3D 激光雷达成像的基于多尺度直方图的概率深度神经网络. 传感器 2023, 23, 420. <https://doi.org/10.3390/s23010420>

学术编辑:Sylvain Girard

收到日期:2022 年 10 月 24 日

修订日期:2022 年 12 月 26 日

录用日期:2022 年 12 月 27 日

发表日期:2022 年 12 月 30 日

(cc) ①

版权: ©2022 作者。瑞士巴塞尔 MDPI 出版社。本文是一篇开放获取文章, 根据知识共享署名 (CC BY) 许可协议 (<https://creativecommons.org/licenses/by/4.0/>) 发布。

为了填补高效硬件使用与算法设计之间的差距, 提出了一种结合新型数据格式和两步神经网络的新算法。首先, 在硬件上采用多尺度直方图以节省片上复杂度并保留更多信息。其次, 提出了概率编码器和超分辨率 (SR)-Net 来恢复深度图并进行上采样。概率编码器负责从直方图箱中提取深度信息。基于这种设计, 首次针对 SPAD 去噪问题引入了基于概率编码器的神经网络。由概率编码器生成的低分辨率深度图像通过 SR-Net 进行上采样。为了恢复高分辨率深度图像, 基于 U-Net 的 SR-Net 对概率编码器的输出深度进行 $4\times$ 上采样。第三, 通过使用开放深度数据集模拟深度图, 在深度传感器中设置的相同参数下针对特定硬件设计训练神经网络, 这保证了在实际测试中的性能。最后, 通过在实验室中测试该算法, 我们表明所提出的解决方案可以从 32×32 多级直方图箱中恢复深度图像, 这证明了从训练数据集到现实世界实现网络时的可行性。本文结构如下: 第 2 节描述了所提出神经网络的原理。第 3 节展示了生成数据集的模拟细节和训练结果。在第 4 节中, 介绍了传感器设计、硬件架构和数据采集。第 5 节将我们的方法与其他先进的激光雷达系统进行了比较。此外, 在第 5 节和第 6 节中进行了讨论和总结。

2. 所提出的概率深度神经网络的原理

时间相关单光子计数 (TCSPC) 作为一种经典方法用于估计距离信息。构建返回光子的完整直方图所需的片上内存占用巨大; 因此, 多尺度直方图是提取峰值的有效方法。然而, 多尺度直方图存在许多问题:(i) 对于返回光子呈现的时间信息, 假设每个像素只有一个表面, 因为峰值提取只能找到一个峰值, 这在物体边缘可能无效。(ii) 对于少数计数的光子, 简单的最大选择标准会非常嘈杂, 可能会导致次优结果, 因为深度估计通过选择光子计数最大的时间箱, 然后运行另一个测量采集来工作, 该采集在较粗尺度上最初选择的箱内对更精细的时间箱进行采样。考虑到部分直方图的这些缺点, 我们提出了一种结合经典多尺度直方图用于时间深度信息提取和基于 U-net 的神经网络用于空间上采样和去噪的组合算法。

如图 1a 所示, 与先前的方法相比, 采用多尺度直方图来节省用于峰值查找的片上内存和计算负载。首先使用图 1b 中的完整直方图来计算每个 bin 的反射光子数。完整直方图在用于峰值查找时会占用巨大的内存区域和计算负载。因此, 设计了部分直方图以节省片上内存和计算负载。然而, 如图 1c 中的部分直方图计算所示, 在放大到下一阶段时, 除峰值外的所有信息都会被丢弃, 这导致深度估计不准确。在所提出的多尺度直方图方法 (图 1d) 中, 将所有 48 个 bin 作为神经网络的输入。通过在模拟数据集上训练神经网络, 以这种方式获得准确的深度图。所提出的神经网络架构如图 2 所示。在每个像素经过 $4k$ 个脉冲后获得三个 16-bin 直方图分布。由于反射光子的分布遵循泊松分布 $\mathcal{P}$, 引入变分自编码器 (VAE)[13] 的编码器部分来学习每个像素每个独立分布的均值 (公式 (1))。采用重参数化技巧来获得均值为 $m_{i,j}$ 、标准差为 $\sigma_{i,j}$ 的高斯分布的估计值。

$$c_i = \exp(\sigma_i) + m_i \quad (1)$$




图 1. 与先前工作的比较:(a) 成像系统, 包括基于垂直腔面发射激光器 (VCSEL) 的发射器、基于单光子雪崩二极管 (SPAD) 的接收器和 12 位时间数字转换器 (TDC) 以计算输出。(b) 传统方法, 其需要 2048 个 bin 并进行峰值查找计算。(c) 改进方法, 将 bin 数量限制为 48 个, 并对 3 个直方图进行峰值查找计算。(d) 本工作中的方法, 其将 48 个 bin 作为输入, 并使用所提出的人工智能神经网络获得深度值。




图 2. 所提出的神经网络架构:(a) 多尺度直方图模式的采样过程。在本实验中, 在每个阶段, 硬件上的 VCSEL 被驱动 4000 次。根据返回的 TDC 结果, 在下一阶段缩小峰值范围。(b) 概率编码器结构, 它结合了基于卷积神经网络 (CNN) 的编码器部分和重参数化技巧。基于 U-Net 的超分辨率网络 (SR-Net) 如图 (c) 所示。SR-Net 负责此神经网络中的上采样任务。

这三个直方图是使用 12 位 TDC 的不同分辨率构建的; 因此, 实际深度分辨率范围从 $\text{TDC} \langle 11:8 \rangle$ 到 $\text{TDC} \langle 7:4 \rangle$, 再到 $\text{TDC} \langle 3:0 \rangle$ 。通过三个多尺度直方图概率编码器分支获得这些初始多尺度深度图, 将它们乘以不同的比例并相加, 作为输入到下一个上采样网络。根据实验, 实际比例对于神经网络的收敛是有效且至关重要的。TDC 的分辨率用作多尺度直方图的先验知识。对于上采样网络, 应用 U-net [14] 架构作为 SR-Net, 它能够很好地处理图像分割和超分辨率问题。此外, 其多级拼接的使用极大地促进了多尺度空间信息的融合。考虑到 SPAD 成像器的硬件特性, 本工作旨在设计一种避免使用其他辅助信息 (如 RGB 图像、反照率图和强度图像) 的算法。尽管 RGB 图像对最终上采样图像质量有很大贡献, 但它对 RGB 图像像素和 SPAD 阵列像素之间的未对准问题提出了挑战。与 RGB 图像相比, 密度图 (置信度图) 是一种替代方法, 它消耗更少的寄存器, 并且从硬件角度获得置信度引导图。由于收集真实 SPAD 测量数据的时间消耗, 本实验中的训练数据集使用具有 18 个场景的 Middlebury 数据集 [15] 进行模拟。与超分辨率任务中使用的其他模拟数据集相比, 为每个训练图像和测试图像生成多尺度直方图。为了模拟多尺度直方图行为, 首先, 以 7680 ps 的 bin 大小模拟具有 16 个 bin 的 SPAD 测量直方图。其次, 将直方图范围缩小到 480 ps, 并保持相同数量的直方图 bin。最后, 在最后阶段每个 bin 具有 30ps 的分辨率。为了容忍真实场景中的不同噪声水平, 信噪比 (SBR) 范围为 0.05 至 5。根据公式 (2) 使用用于训练神经网络的模拟数据。

$$h_m[n] \sim \mathcal{P}(\mathcal{N}(\eta\gamma\tau[n] + \eta\alpha + d)) \quad (2)$$

其中, n 是来自对象的样本索引, η 是检测效率, γ 是与距离和对象材料相关的反射因子。到达光子的数量 τ 对于像素 (i, j) 遵循独立分布。环境光子 α 由背景光产生, 例如荧光灯、阳光和其他潜在光源。SPAD 的热噪声也会带来一些错误计数 (d)。此外, 概率编码器输出与真实距离之间的误差使用 $\mathcal{L}_2$ 进行评估 (表示为均方误差; 公式 (3))。

$$\mathcal{L}_2 = \text{MSE}(\exp(\sigma_i) + m_i - d_i) \quad (3)$$

在实际实验室条件下, 原始深度值使用最大似然估计 (MLE) 计算。深度值在实验室中使用完整直方图计算, $d_{i,j}$ 使用公式 (4) 估计 (引自 [10])。

$$d_{i,j} = \frac{\sum_{t=\max(1, d^{\max}-1)}^{T, d^{\max}+1} t * \max(0, h_{i,j,t} - b_{i,j})}{\sum_{t=\max(1, d^{\max}-1)}^{T, d^{\max}+1} \max(0, h_{i,j,t} - b_{i,j})} \quad (4)$$

其中, b 是用作测量环境水平的箱的中位数。

整个神经网络损失 L (公式 (5)) 由概率编码器预测的初始深度与来自地面真值的 32×32 下采样深度值之间的均方根误差 (RMSE)、上采样深度图像误差的损失以及 128×128 原始深度值组成。

$$\mathcal{L} = \lambda * \text{RMSE}(x, \hat{x}) + (1 - \lambda) * \text{MSE}(\exp(\sigma_i) + m_i - d_i) \quad (5)$$

3. 模拟设置与实验

图 3 展示了使用 $\text{SBR} = 5$ 的测试数据集的三个多尺度直方图的模拟图像。图 3a 显示了测试数据集中的一张地面真值图像。TDC<11:8>、TDC<7:4> 和 TDC<3:0> 的处理后的峰值图像分别显示在列 (b)、(c) 和 (d) 中。在本实验中, TDC<11:8> 的粗略范围显示了检测对象的最粗略范围, 分辨率为 7680 ps, 这意味着列 (b) 中的距离范围高于 1.115。在列 (c) 中, 位于 TDC<7:4> 中的数据包含对象的丰富轮廓信息; 因此, 模拟数据集中的最大深度值在 2 m 和 3 m 之间。列 (c) 显示了与原始对象表面相似的分布。在列 (d) 中, TDC<3:0> 的最低四位填充了更多细节, 显示了对象表面的微小变化。经过 100 个 epoch 的训练, 神经网络在测试数据集上实现了更低的 RMSE, 为 0.022 m。




图 3. 基于 Middlebury 数据集的本工作中使用的模拟数据。(a) 用于生成概率编码器的多尺度直方图行为输入的原深度图像。(b - d) $SBR = 5$ 时三级输出的峰值。(e) 本工作的输出结果。

4. 芯片描述与数据采集

图 4 介绍了 SPAD 阵列和 TDC 的框图。该传感器由直径为 $25\text{ }\mu\text{m}$ 的 128×128 个 SPAD 和 32 个共享 TDC 组成。在 70°C 下以 100 kcps 的暗计数率 (DCR) 进行测量，在 940 nm 时光子检测概率 (PDP) 为 1% 。在 14 个信号光子和所有像素平均 450 个噪声实例的测量 SNR 条件下，低分辨率直方图由 4×4 组合像素采样。考虑到粗粒度 TDC 带来的影响，三个阶段的采样数配置为 2k, 1k 和 1k。在 TDC 的整个动态范围内，每个检测的模拟概率 SNR 为 $14/450$ ，并且有数千个脉冲用于执行直方图计算。




图 4. 具有 32 个线共享 TDC 和由 4×4 像素组合的 32×32 个宏 SPAD 阵列的测试芯片的框图。

图 5 展示了包括 SPAD 阵列和 VCSEL 的硬件平台 [16]。SPAD 阵列采用 TSME 180 nm 技术制造。 32×32 SPAD 阵列 (图 5a) 的 SPAD 尺寸为 128×128 ，并且每个 4×4 SPAD 阵列组合作为一个输出以获得 32×32 深度图。成像系统的原型如图 5b 所示，其与图 5c 中所示的距离为 1 m 的目标雕像平行设置。VCSEL 发射的波长为 940 nm，并且激光脉冲设置为 1 ns。该算法在具有宽光谱范围 (350 - 2500 nm) 的卤素灯下进行测试，并且在室内环境中背景计数平均为 240kpcs。为了提高算法的鲁棒性，第一阶段需要比后两个阶段采样更多的数据。如图 1a 所示，VCSEL 以 2k, 1k 驱动，并且在每个阶段的多尺度直方图模式下驱动 1k 次。




图 5. 实验装置:(a) SPAD 传感器的布局图和重要电路的放置。(b) 本实验中的评估板，其采用片上多尺度直方图电路设计制造。(c) 室内目标物体。

为了使神经网络推理时间可接受，在这项工作中于算法端设计了一个深度学习加速器 (DLA)。如图 6 所示，DLA 由 512 个 MAC 和 512 KB 的片上乒乓 SRAM 组成，用于存储中间特征和权重。处理元件 (PE) 阵列配置为 16 个原子通道和 32 个原子内核操作。通过使用 Pytorch 中的深度学习加速器工具对 DLA 进行建模，对所提出的神经网络的加速性能进行了估计。所采用的 DLA 使用 Verilog 实现，并在台积电 40 nm 工艺下使用 DC 编译器在 500MHz 进行综合。综合后的系统性能如表 1 所示，并且与其他激光雷达系统的功耗和帧率比较报告在表 2 中。




图 6. 所采用的 DLA 架构图。

表 1. DLA 的综合结果。

PE 编号	512
频率 (MHz)	500
面积 (mm ²)	2.55
功率 (mW)	306.82
能效 (TOPS/W)	2

表 2. 系统性能总结与比较表。

参数	本作品	[17]	[18]
像素阵列	16×16	80 × 60	48 × 40
波长 (纳米)	940	905	905
TDC 类型	像素内	像素内	像素内
TDC 频率 (兆赫兹)	10	0.1	0.1
TDC 位宽 (位)	多级 12	粗 6 细 7	粗 7 细 6
TDC 分辨率 (皮秒)	120	100-5000	90-5000
帧率 (帧每秒)	20	30	无
深度精度 (厘米)	2	1.5	2.34-4
功率 (毫瓦)	150(传感器)306.82(DLA)	1500	840
成像分辨率	128×128	80 × 60	42 × 25

5. 结果与讨论

所提出的神经网络在硬件上的验证结果如图 7 所示。在图 7a - c 中，多尺度直方图的峰值图与模拟数据一致，这支持了该算法在硬件上的可行性。关于检测到的物体的边缘，接收器会被背景反射的一些光子触发。在图 7a 中，轮廓上的距离值受到背景点的影响，这些背景点呈现出各种颜色，即飞噪。根据图 7d

中的输出结果, 所提出的神经网络在提取该实验装置的深度图方面是有效的, 并且很好地恢复了雕像的细节。

相关研究工作的性能总结在图 8 中。本工作中提出的 SR - Net 恢复了检测到的物体更详细的深度特征。在图 [16] 中, 采用了与 SR - Net 相同的主干, 但 [16] 中提出的基于机器学习的空间分辨率提升模型未能提高信噪比, 并且散斑噪声明显。在 [10] 中, 结果保留了 SPAD 传感器的固有失真特征, 包括行偏移, 可以使用卷积神经网络进行校正。




图 7. 实验室测试结果:(a - c) 三个阶段的多尺度直方图箱的峰值。(d) 应用 SR - Net 后的目标雕像结果。



	这项工作	卓, S. 2022	京伊, I. 2020
报告结果			
方法	SR - 网络	基于机器学习的空间分辨率提升	最大似然估计
像素数量	32x32	32x32	128x128
输入	32x32 三级直方图	32x32 深度图 + 128x128 强度图	128x128 全直方图

图 8. 本工作与最先进的直接飞行时间 (dToF) 激光雷达系统 [16] 和经典 dToF 估计方法 [10] 的性能比较。

图 9 展示了使用最大似然估计 (公式 (4)) 和 SR-Net 获得的不同结果。与 128×128 阵列输出相比, 可以观察到雕像更多的特定特征, 但不太平滑。通过放大子图中的细节, 可以在该推理结果中观察到上采样网络常见的“网格效应”。可以通过添加其他信息 (例如 RGB 图像) 或扩大神经网络规模来消除网格效应。所提出的结合概率编码器和 SR-Net 的神经网络是一种实用的方法, 可将原始直方图区间数据用作输入来上采样高分辨率深度图。所提出的结合概率编码器和 SR-Net 的神经网络是一种实用的方法, 可将原始直方图区间数据用作输入来上采样高分辨率深度图。




图 9. 与最大似然估计的比较。上采样神经网络产生的“网格效应”显示为子图像。

6. 结论

在本工作中，与片上直方图峰值计算算法相比，提出了结合概率编码器和 SR-Net 的神经网络用于对具有多尺度直方图输出的深度图进行上采样。在算法部分，本工作采用概率编码器的编码器网络，这首先节省了在 SPAD 成像系统中检测直方图峰值的硬件消耗。为了验证算法，使用米德尔伯里 (Middlebury) 数据集生成了基于 SPAD 特性的模拟数据集。通过训练上采样网络，本工作提出的方法在生成的数据集上恢复了尺寸为 $16\times$ 、分辨率为 $RMSE = 0.022\text{ m}$ 的深度图像。在硬件平台方面，从 32×32 传感器成像系统提取多尺度直方图区间，并重新缩放至具有丰富细节的 128×128 深度图。通过将算法植入深度学习加速器，降低了整个神经网络的延迟，帧率达到 20fps，与其他最先进的工作相比具有竞争力。所提出的 SPAD 成像系统提供了硬件和软件协同设计的视角。此外，本工作未来可能能够将上采样从 $32\times$ 扩展到 $64\times$ 。

作者贡献: 方法学, S.Z.; 写作—审阅与编辑, M.S.; 监督, P.Y.C. 所有作者已阅读并同意发表的稿件版本。

资金: 本研究未获得外部资金。

数据可用性声明: 不适用数据共享。

利益冲突: 作者声明无利益冲突。

参考文献

1. Zhang, C.; Lindner, S.; Antolovic, I.M.; Wolf, M.; Charbon, E. A CMOS SPAD imager with collision detection and 128 dynamically reallocating TDCs for single-photon counting and 3D time-of-flight imaging. *Sensors* 2018, 18, 4016. [CrossRef] [PubMed]
2. Morimoto, K.; Ardelean, A.; Wu, M.L.; Ulku, A.C.; Antolovic, I.M.; Bruschini, C.; Charbon, E. Megapixel time-gated SPAD image sensor for 2D and 3D imaging applications. *Optica* 2020, 7, 346-354. [CrossRef]
3. Morimoto, K.; Charbon, E. High fill-factor miniaturized SPAD arrays with a guard-ring-sharing technique. *Opt. Express* 2020, 28, 13068-13080. [CrossRef] [PubMed]
4. Dutton, N.A.; Gnechhi, S.; Parmesan, L.; Holmes, A.J.; Rae, B.; Grant, L.A.; Henderson, R.K. 11.5 A time-correlated single-photon-counting sensor with 14GS/S histogramming time-to-digital converter. In *Proceedings of the 2015 IEEE International Solid-State Circuits Conference-(ISSCC) Digest of Technical Papers*, San Francisco, CA, USA, 22-26 February 2015; pp. 1-3.